

UNIVERSIDADE ANHEMBI MORUMBICIÊNCIA DA COMPUTAÇÃO

GUILHERME P. VALE – 1252327540LUAN GONÇALVES SPERA – 1252322579YAN MOMBELI DE CARVALHO –
1252328669MATHEUS VINÍCIUS INAGAKI MORAES – 12523220249NICOLAS GOMES JULIAO DA SILVA –
12525177120

MODELO DE CLASSIFICAÇÃO PARA DIAGNÓSTICO DE DIABETESUTILIZANDO MACHINE LEARNING

São Paulo2026

GUILHERME P. VALELUAN GONÇALVES SPERAYAN MOMBELI DE CARVALHOMATHEUS VINÍCIUS INAGAKI
MORAESNICOLAS GOMES JULIAO DA SILVA

MODELO DE CLASSIFICAÇÃO PARA DIAGNÓSTICO DE DIABETESUTILIZANDO MACHINE LEARNING

Trabalho apresentado ao curso de Ciência de Dados da Universidade Anhembi Morumbi.

Orientador: Prof. Paulo Sergio Gonçalves de Oliveira

São Paulo2026

RESUMO

Este trabalho apresenta o desenvolvimento de um modelo de aprendizado de máquina para a identificação de casos de diabetes a partir de indicadores de saúde do Behavioral Risk Factor Surveillance System (BRFSS) de 2015. O conjunto de dados original contém 441.455 registros e 22 variáveis preditoras. O objetivo principal foi maximizar o Recall da classe positiva, minimizando falsos negativos, dada a criticidade clínica. Foram aplicadas etapas de limpeza, tratamento de outliers no IMC, binarização da variável alvo e balanceamento com SMOTE-NC. Cinco algoritmos foram avaliados (Regressão Logística, Random Forest, XGBoost, LightGBM e KNN) dentro de um pipeline com otimização de hiperparâmetros via Optuna. Os melhores resultados foram obtidos pela Regressão Logística (AUC = 0,81; menor número de falsos negativos) e Random Forest (AUC = 0,81; melhor equilíbrio). O modelo foi serializado com joblib para uso futuro.

Palavras-chave: Diabetes. Machine Learning. SMOTE-NC. Classificação. BRFSS.

SUMÁRIO

1 INTRODUÇÃO	4
2 OBJETIVOS	4
3 FUNDAMENTAÇÃO TEÓRICA	5
4 METODOLOGIA	5
5 DESENVOLVIMENTO E RESULTADOS	7
6 CONCLUSÃO	11
REFERÊNCIAS	12

1 INTRODUÇÃO

O diabetes mellitus representa um dos principais desafios de saúde pública, com alta prevalência e custos associados a complicações tardias. A detecção precoce, especialmente de pré-diabetes, permite intervenções que reduzem significativamente a progressão da doença. Neste contexto, modelos preditivos baseados em dados populacionais podem auxiliar profissionais de saúde na triagem de risco.

Este projeto utiliza o dataset Diabetes Health Indicators (BRFSS 2015), disponibilizado no Kaggle, que reúne respostas de mais de 400 mil americanos sobre comportamentos de risco, condições crônicas e acesso a serviços preventivos. O trabalho foi implementado em Python, com foco em um pipeline reproduzível e avaliado por métricas clínicas relevantes.

2 OBJETIVOS

Objetivo Geral:

Desenvolver um modelo de Machine Learning capaz de identificar casos de diabetes e pré-diabetes, otimizando seu desempenho por meio de tratamento de dados, seleção de variáveis e ajuste de hiperparâmetros.

Objetivos Específicos:

- Realizar limpeza e análise exploratória dos dados do BRFSS 2015;
- Tratar desbalanceamento de classes com SMOTE-NC;
- Comparar cinco algoritmos de classificação;
- Otimizar hiperparâmetros com Optuna visando maximizar o Recall;
- Avaliar os modelos por meio de Curva ROC e Matriz de Confusão.

3 FUNDAMENTAÇÃO TEÓRICA

Foram utilizadas técnicas de aprendizado supervisionado para classificação binária. A Regressão Logística oferece interpretabilidade e bom desempenho em dados tabulares. Random Forest, XGBoost e LightGBM são métodos baseados em árvores com alta capacidade de capturar interações não lineares. O KNN serve como baseline não paramétrico.

Devido ao desbalanceamento natural da variável alvo, aplicou-se SMOTE-NC, que gera amostras sintéticas respeitando variáveis categóricas. A otimização bayesiana com Optuna permite busca eficiente de hiperparâmetros.

4 METODOLOGIA

4.1 Tecnologias Utilizadas

- Python, NumPy e Pandas: manipulação de dados;
- Scikit-learn: pré-processamento, métricas e modelos base;
- XGBoost e LightGBM: gradient boosting;
- Imbalanced-learn: pipeline e SMOTE-NC;
- Optuna: otimização de hiperparâmetros;
- Matplotlib e Seaborn: visualização;
- Joblib: persistência de modelos.

4.2 Base de Dados

Dataset: diabetes_012_health_indicators_BRFSS2015.csv (Kaggle). Variável original Diabetes_012 (0=sem diabetes, 1=pré-diabetes, 2=diabetes) foi convertida para Diabetes_Binary (0 vs 1), unindo pré-diabetes e diabetes como classe positiva.

4.3 Pré-processamento

As etapas executadas foram:

- Remoção de outliers de BMI ≥ 80 , conforme análise de boxplot;
- Verificação de duplicatas e valores nulos;
- Conversão de colunas para int8;
- Divisão estratificada: 60% treino, 20% validação, 20% teste;
- Padronização de variáveis contínuas com StandardScaler;
- Aplicação de SMOTE-NC dentro do pipeline.




Figura 1 – Tratamento de outliers na variável BMI

Fonte: Autoria própria (2026).

A Figura 1 demonstra o efeito da filtragem: à esquerda, outliers comprimiam a distribuição; à direita, a escala ajustada permite melhor interpretação.




Figura 2 – Mapa de correlação entre variáveis

Fonte: Autoria própria (2026).

A análise indicou associações moderadas entre Diabetes_Binary e HighBP (0,42), HighChol (0,58) e BMI (0,35).




Figura 3 – Distribuição da variável alvo após binarização

Fonte: Autoria própria (2026).

5 DESENVOLVIMENTO E RESULTADOS

O pipeline foi estruturado com ColumnTransformer, SMOTE-NC e classificador. A otimização com Optuna (10 trials por modelo) maximizou o Recall no conjunto de validação.

5.1 Avaliação Comparativa




Figura 4 – Curvas ROC comparativas

Fonte: Autoria pr pria (2026).

LogisticRegression e RandomForestClassifier atingiram AUC de 0,81, seguidos por XGBoost e LightGBM (0,79) e KNN (0,76).




Figura 5 – Matrizes de confus o dos modelos otimizados

Fonte: Autoria própria (2026).

• LogisticRegression: 1.888 falsos negativos e 12.038 falsos positivos; • RandomForest: 2.271 falsos negativos, com redução de falsos positivos; • Boosting apresentou desempenho intermediário.

Tabela 1 – Resumo de desempenho (teste)

Modelo	AUC	Falsos Negativos	Falsos Positivos
LogisticRegression	0,81	1.888	12.038
RandomForest	0,81	2.271	10.538
XGBoost	0,79	2.500	11.038
LightGBM	0,79	2.480	11.138
KNN	0,76	3.000	13.038

Fonte: Autoria própria (2026).

6 CONCLUSÃO

O trabalho cumpriu o objetivo de construir um pipeline completo para diagnóstico de diabetes. A Regressão Logística foi selecionada como modelo final por apresentar o menor número de falsos negativos, priorizando sensibilidade clínica. O Random Forest é alternativa equilibrada quando o custo de falso positivo é relevante.

REFERÊNCIAS

CENTERS FOR DISEASE CONTROL AND PREVENTION. Behavioral Risk Factor Surveillance System (BRFSS) 2015.

KAGGLE. Diabetes Health Indicators Dataset. Disponível em:
<https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset>

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. JMLR, 2011.

CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. KDD, 2016.

KE, G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NIPS, 2017.

AKIBA, T. et al. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD, 2019.

LEMAÎTRE, G. et al. Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets. JMLR, 2017.